

Aula 2: Análise de séries temporais univariadas (ARIMA)

Marcus L. Nascimento

6 de outubro de 2025

1. Introdução
2. Séries Temporais Lineares
3. Processos Autorregressivos (AR)
4. Processos de Médias Móveis (MA)
5. Processos Autorregressivos de Médias Móveis (ARMA)

Introdução

- **Série temporal:** Sequência de variáveis aleatórias Y_1, Y_2, \dots, Y_n indexadas no tempo ($t = 1, 2, \dots, n$).
 - Por vezes, denotamos a sequência de variáveis aleatórias por $Y_{t_1}, Y_{t_2}, \dots, Y_{t_n}$;
 - Frequentemente, tal sequência é considerada um subconjunto de uma sequência (possivelmente, infinita) $\{Y_t\}$ de variáveis aleatórias.
- Propósito em análise de séries temporais:
 - **Quantificar dependências** no tempo;
 - **Utilizar as correlações** para **explicar** as observações disponíveis e **inferir** sobre valores não observados.

- Um conceito fundamental em análise de séries temporais recai sobre a ideia de **estacionariedade**.
 - Medidas estatísticas (por exemplo, média, variância e correlação) são constantes ao longo do tempo;
 - Estabilidade no processo gerador subjacente facilita a identificação de padrões e relações nos dados;
 - Modelos estatísticos e de aprendizado de máquinas pressupõem estacionariedade.
- Estacionariedade **estrita** e **fraca**.

Estacionariedade estrita

DEFINIÇÃO: Uma série temporal $\{Y_t\}$ é dita **estritamente estacionária** se a distribuição conjunta de $(Y_{t_1}, \dots, Y_{t_k})$ é idêntica à distribuição de $(Y_{t_1+s}, \dots, Y_{t_k+s})$ para todo s , onde k é um número inteiro positivo arbitrário e (t_1, \dots, t_k) é uma coleção de k inteiros positivos.

OBSERVAÇÕES:

- A distribuição conjunta de $(Y_{t_1}, \dots, Y_{t_k})$ é invariante sob translações temporais;
- Estacionariedade estrita é uma condição bastante forte;
- Difícil verificação empírica.

Estacionariedade fraca (segunda ordem)

DEFINIÇÃO: Uma série temporal $\{Y_t\}$ é dita **fracamente estacionária** (ou estacionária de segunda ordem) se a média de Y_t e a covariância entre Y_t e Y_{t-l} são invariantes no tempo, onde l é um número inteiro arbitrário.


Mais especificamente, $\{Y_t\}$ é dita fracamente estacionária se:

1. $\mu_Y(t) = E(Y_t) = \mu, |\mu| < \infty$;
2. $\sigma_Y^2(t) = E[(Y_t - \mu)^2] = \gamma_0, \gamma_0 < \infty$;
3. $\gamma_Y(t, t-l) = \text{Cov}(Y_t, Y_{t-l}) = E[(Y_t - \mu)(Y_{t-l} - \mu)] = \gamma_l \forall l$ com $|\gamma_l| < \infty$.


Estacionariedade de segunda ordem implica que $\text{Cov}(Y_{t_1}, Y_{t_1-l}) = \text{Cov}(Y_{t_2}, Y_{t_2-l}) = \gamma_l$.

Estacionariedade Fraca

(a) Stationary



(b) Nonstationary



Função de autocorrelação (ACF)

- Sob estacionariedade fraca, a função de autocorrelação de defasagem l (lag l) é dada por:

$$\rho_l = \rho_Y(t, t-l) = \text{Corr}(Y_t, Y_{t-l}) = \frac{\gamma_Y(t, t-l)}{\sqrt{\sigma_Y^2(t)\sigma_Y^2(t-l)}} = \frac{\gamma_l}{\gamma_0}$$

- A autocorrelação amostral de defasagem l (lag l), por sua vez, é definida como

$$\hat{\rho}_l = \frac{\sum_{t=l+1}^n (y_t - \bar{y})(y_{t-l} - \bar{y})}{\sum_{t=1}^n (y_t - \bar{y})^2}, \quad 0 \leq l < n-1.$$

Função de autocorrelação (ACF) - Teste de Portmanteau

- A verificação quanto à presença ou não de autocorrelação em uma série temporal pode ser realizada através de testes de hipótese da seguinte forma:

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_m = 0$$

$$H_1 : \rho_i \neq 0 \text{ para algum } i \in \{1, 2, \dots, m\}.$$

- Proposto por Box and Pierce (1970), o teste de Portmanteau aplica a seguinte estatística de teste:

$$Q^*(m) = n \sum_{l=1}^m \hat{\rho}_l^2.$$

- Assumindo que $\{Y_t\}$ é uma sequência de variáveis aleatórias independentes e identicamente distribuídas (i.i.d) com certas condições acerca dos momentos, $Q^*(m)$ é assintoticamente χ_m^2 .

Função de autocorrelação (ACF) - Teste de Ljung-Box

- Com intuito de aumentar o poder do teste em amostras finitas, Ljung and Box (1978) propuseram uma modificação na estatística $Q^*(m)$ da seguinte forma:

$$Q(m) = n(n+2) \sum_{l=1}^m \frac{\hat{\rho}_l^2}{n-1}.$$

- Neste caso, a regra de decisão é rejeitar H_0 se $Q(m) > q_{\alpha}^2$, onde:
 - q_{α}^2 denota o $100(1 - \alpha)$ -ésimo percentil da distribuição χ_m^2 ;
 - α é um nível de significância fixado.

Função de autocorrelação parcial (PACF)

- Em geral, o conceito de correlação parcial se refere a uma correlação condicional.
- No contexto de séries temporais, a autocorrelação parcial entre Y_t e Y_{t-l} é definida como a correlação entre Y_t e Y_{t-l} condicional em $Y_{t-l+1}, \dots, Y_{t-1}$ (conjunto de observação entre os tempos t e $t-l$).

$$\phi_{l,l} = \frac{\text{Cov}(Y_t, Y_{t-l} | Y_{t-l+1}, \dots, Y_{t-1})}{\sqrt{\text{Var}(Y_t | Y_{t-l+1} = y_{t-l+1}, \dots, Y_{t-1} = y_{t-1}) \text{Var}(Y_{t-l} | Y_{t-l+1} = y_{t-l+1}, \dots, Y_{t-1} = y_{t-1})}}$$

EXEMPLOS:

- A autocorrelação parcial de primeira ordem é definida para ser igual à autocorrelação de primeira ordem;
- Autocorrelação de segunda ordem: $\phi_{2,2} = \frac{\text{Cov}(Y_t, Y_{t-2} | Y_{t-1})}{\sqrt{\text{Var}(Y_t | Y_{t-1} = y_{t-1}) \text{Var}(Y_{t-2} | Y_{t-1} = y_{t-1})}};$

Séries Temporais Lineares

- Uma série temporal $\{W_t\}$ é denominada **ruído branco** se $\{W_t\}$ é uma sequência de variáveis aleatórias independentes e identicamente distribuídas com média 0 e variância constante τ^2 finita.
 - $\{W_t\}$ é estacionária;
 - Se $s \neq t$, $\text{Cov}(W_s, W_t) = E[(W_s - \mu)(W_t - \mu)] = 0$;
 - $\rho_l = 0$ para todo l .
- Se W_t tem distribuição normal com média 0 e variância τ^2 , a série temporal é denominada ruído branco Gaussiano.

Série temporal linear

- Uma série temporal $\{Y_t\}$ é dita linear se pode ser escrita da seguinte forma:

$$y_t = \mu + \sum_{i=0}^{\infty} \psi_i w_{t-i},$$

onde μ é a média de Y_t , $\psi_0 = 1$ e $\{W_t\}$ é ruído branco.

- w_t denota a nova informação da série temporal no tempo t e é frequentemente chamado de inovação ou choque em t .
- Se $\{Y_t\}$ é fracamente estacionária, pela independência de $\{W_t\}$, $E(Y_t) = \mu$ e $\text{Var}(Y_t) = \tau^2 \sum_{i=0}^{\infty} \psi_i^2$.

Série temporal linear

- A covariância de defasagem l , $\gamma_Y(t, t-l)$, é dada por:

$$\begin{aligned}\gamma_Y(t, t-l) &= \text{Cov}(Y_t, Y_{t-l}) \\ &= E \left[\left(\sum_{i=0}^{\infty} \psi_i w_{t-i} \right) \left(\sum_{j=0}^{\infty} \psi_j w_{t-l-j} \right) \right] \\ &= E \left(\sum_{i,j=0}^{\infty} \psi_i \psi_j w_{t-i} w_{t-l-j} \right) \\ &= \sum_{j=0}^{\infty} \psi_{j+l} \psi_j E(w_{t-l-j}^2) = \tau^2 \sum_{j=0}^{\infty} \psi_{j+l} \psi_j.\end{aligned}$$

- Modelos lineares de séries temporais são modelos estatísticos e econométricos utilizados para descrever o padrão dos pesos ψ de Y_t .

Processos Autorregressivos (AR)

Processo Autorregressivo de Ordem 1 - AR(1)

- Seja $\{W_t\}$ ruído branco, um processo AR(1) pode ser descrito como a seguir:

$$y_t = \phi_1 y_{t-1} + w_t.$$

- Por recursão, podemos mostrar que um processo AR(1) pode ser descrito como um modelo linear de série temporal.

$$\begin{aligned} y_t &= \phi_1 y_{t-1} + w_t \\ &= \phi_1 (\phi_1 y_{t-2} + w_{t-1}) + w_t \\ &= \phi_1 (\phi_1 (\phi_1 y_{t-3} + w_{t-2}) + w_{t-1}) + w_t \\ &\vdots \\ &= \sum_{i=0}^{\infty} \phi_1^i w_{t-i}. \end{aligned}$$

Processo Autorregressivo de Ordem 1 - AR(1)

- Sob estacionariedade, temos que

$$\begin{aligned}\text{Var}(Y_t) &= \text{Var}(\phi_1 Y_{t-1} + W_t) \\ &= \text{Var}(\phi_1 Y_{t-1}) + \text{Var}(W_t) \\ &= \phi_1^2 \text{Var}(Y_{t-1}) + \tau^2 \\ &= \frac{\tau^2}{1 - \phi_1^2},\end{aligned}$$

$\phi_1^2 < 1$. Em outras palavras, a estacionariedade fraca de um modelo AR(1) implica que $|\phi_1| < 1$.

Processo Autorregressivo de Ordem 1 - AR(1)

- Ainda sob estacionariedade, temos que

$$\begin{aligned}\gamma_l &= \gamma_Y(t, t-l) = \text{Cov}(Y_t, Y_{t-l}) = E(Y_t Y_{t-l}) \\ &= E((\phi_1 Y_{t-1} + W_t) Y_{t-l}) \\ &= \phi_1 E(Y_{t-1} Y_{t-l}) + E(W_t Y_{t-l}) \\ &= \phi_1 E(Y_{t-1} Y_{t-l}) \\ &= \phi_1^2 E(Y_{t-2} Y_{t-l}) \\ &\vdots \\ &= \phi_1^l E(Y_{t-l} Y_{t-l}) \\ &= \phi_1^l E(Y_t Y_t) \\ &= \phi_1^l \gamma_0,\end{aligned}$$

para $l = -1, 1, -2, 2, \dots$

Processo Autorregressivo de Ordem 1 - AR(1)

- Para encontrar γ_0 , basta seguirmos de forma similar.

$$\begin{aligned}\gamma_0 &= E(Y_t Y_t) \\ &= E((\phi_1 Y_{t-1} + W_t) Y_t) \\ &= \phi_1 E(Y_{t-1} Y_t) + E(W_t Y_t) \\ &= \phi_1 \gamma_1 + \tau^2.\end{aligned}$$

- Como $\gamma_1 = \phi_1 \gamma_0$ e $\gamma_0 = \phi_1 \gamma_1 + \tau^2$, segue que $\gamma_0 = \frac{\tau^2}{1-\phi_1^2}$.
- A função de autocorrelação de um modelo AR(1), portanto, é dada por $\rho_l = \frac{\gamma_l}{\gamma_0} = \phi_1^l$, para $l = -1, 1, -2, 2, \dots$

Processo Autorregressivo de Ordem 2 - AR(2)

- Seja $\{W_t\}$ ruído branco, um processo AR(2) assume a seguinte forma:

$$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + w_t.$$

- Para encontrar a função de covariância do modelo AR(2), aplicamos ideias similares às aplicadas no modelo AR(1).

$$\begin{aligned}\gamma_l &= E(Y_t Y_{t-l}) \\ &= E((\phi_1 Y_{t-1} + \phi_2 Y_{t-2} + W_t) Y_{t-l}) \\ &= \phi_1 E(Y_{t-1} Y_{t-l}) + \phi_2 E(Y_{t-2} Y_{t-l}) \\ &= \phi_1 \gamma_{l-1} + \phi_2 \gamma_{l-2} + E(W_t Y_{t-l}).\end{aligned}$$

Processo Autorregressivo de Ordem 2 - AR(2)

$$\begin{aligned}(l = 0) : \gamma_0 &= \phi_1 \gamma_{-1} + \phi_2 \gamma_{-2} + E(W_t Y_{t-l}) \\ \gamma_0 &= \phi_1 \gamma_1 + \phi_2 \gamma_2 + \tau^2\end{aligned}$$

$$\begin{aligned}(l = 1) : \gamma_1 &= \phi_1 \gamma_0 + \phi_2 \gamma_1 + E(W_t Y_{t-l}) \\ &= \phi_1 \gamma_0 + \phi_2 \gamma_1 \\ &= \frac{\phi_1}{1 - \phi_2} \gamma_0\end{aligned}$$

$$\begin{aligned}(l = 2) : \gamma_2 &= \phi_1 \gamma_1 + \phi_2 \gamma_0 + E(W_t Y_{t-l}) \\ &= \phi_1 \gamma_1 + \phi_2 \gamma_0 \\ &= \left[\frac{\phi_1^2}{1 - \phi_2} + \phi_2 \right] \gamma_0\end{aligned}$$

Processo Autorregressivo de Ordem 2 - AR(2)

Substituindo γ_1 e γ_2 em γ_0 , temos:

$$\begin{aligned}\gamma_0 &= \frac{\phi_1^2}{1 - \phi_2} \gamma_0 + \left[\frac{\phi_2 \phi_1^2}{1 - \phi_2} + \phi_2^2 \right] \gamma_0 + \tau^2 \\ &= \frac{(1 - \phi_2) \tau^2}{(1 - \phi_2) - \phi_1^2(1 + \phi_2) + \phi_2^2(1 - \phi_2)}.\end{aligned}$$

A função de autocorrelação, por sua vez, é dada por:

$$\begin{aligned}\rho_l &= \frac{\gamma_l}{\gamma_0} \\ &= \phi_1 \frac{\gamma_{l-1}}{\gamma_0} + \phi_2 \frac{\gamma_{l-2}}{\gamma_0} \\ &= \phi_1 \rho_{l-1} + \phi_2 \rho_{l-2}.\end{aligned}$$

Processo Autorregressivo de Ordem 2 - AR(2)

- Note que, a partir dos resultados encontrados para as covariâncias, conhecendo os valores para as funções γ_0 , γ_1 e γ_2 , é possível um sistema com três equações e três parâmetros desconhecidos (ϕ_1 , ϕ_2 e τ^2)
- Equações de Yule-Walker.
- Substituindo os valores teóricos de γ_0 , γ_1 , γ_2 por suas estimativas $\hat{\gamma}_0$, $\hat{\gamma}_1$, $\hat{\gamma}_2$, obtemos estimativas $\hat{\phi}_1$, $\hat{\phi}_2$ e $\hat{\tau}^2$.
- Tal método é de simples implementação e é utilizado no ajuste de modelos autorregressivos (uma vez que a ordem tenha sido fixada).
- Também aplicado em modelos autorregressivos mais gerais (ordem p). Neste caso, temos um sistema linear com $(p + 1)$ equações e $(p + 1)$ parâmetros.

Processo Autorregressivo de Ordem p - AR(p)

- Os resultados para os modelos AR(1) e AR(2) podem ser generalizados para um modelo AR(p):

$$y_t = \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + w_t,$$

onde p é um inteiro não negativo e $\{W_t\}$ é um ruído branco.

- De forma mais geral, $\{Y_t\}$ é AR(p) se existe ϕ_0 tal que $\{(Y_t - \phi_0)\}$ é AR(p).
- Neste caso, o valor esperado de Y_t é dado por:

$$E(Y_t) = \frac{\phi_0}{1 - \phi_1 - \dots - \phi_p}.$$

Processo Autorregressivo de Ordem p - AR(p)

- Vimos que é possível estimar os parâmetros do modelo a partir de um sistema de equações uma vez fixada a ordem do processo autorregressivo.
- Uma pergunta relevante neste caso seria como definimos a ordem do processo autorregressivo neste caso.
- Considerando um modelo AR(p) estacionário Gaussiano temos os seguintes resultados para a função de autocorrelação parcial (PACF) amostral:
 - $\hat{\phi}_{p,p} \rightarrow \phi_p, n \rightarrow \infty$;
 - $\hat{\phi}_{l,l} \rightarrow 0$ para todo $l > p$;
 - $\text{Var}(\hat{\phi}_{l,l}) \rightarrow 1/n$ para todo $l > p$.
- Tais resultados indicam que o PACF de um modelo AP(p) zera na defasagem p .

Processo Autorregressivo de Ordem p - AR(p)

- Uma alternativa a identificação da ordem de um processo autorregressivo via função de autocorrelação parcial (PACF) se dá através de critérios de seleção de modelos.
- Para identificação da ordem de um processo AR via critérios de seleção de modelos, seguimos os seguintes passos:
 1. Ajuste de modelos AR com diferentes ordens;
 2. Calcule o critério para cada um dos modelos;
 3. Selecione o modelo com melhor métrica.
- Dentre os critérios de seleção de modelos, destacamos o AIC (Akaike Information Criterion) e o BIC (Bayesian information criterion).

Processo Autorregressivo de Ordem p - $AR(p)$

- O AIC (Akaike Information Criterion) é dado pela seguinte equação;

$$AIC = \underbrace{-2 \times \log(\text{verossimilhança})}_{\text{bondade do ajuste}} + \underbrace{2 \times (\text{número de parâmetros})}_{\text{penalização}},$$

onde a verossimilhança é avaliada considerando o modelo estimado.

- Considerando um modelo $AR(p)$ estimado utilizando Yule-Walker, ao invés de avaliar a função de verossimilhança, podemos aplicar:

$$AIC = n \times (\log(\tilde{\tau}^2) + 1) + 2(p + 1),$$

onde n é o tamanho da amostra e $\tilde{\tau}^2$ é o valor estimado para a variância do ruído branco (τ^2).

Processo Autorregressivo de Ordem p - AR(p)

- O BIC (Bayesian information criterion), por sua vez, é dado pela seguinte equação;

$$\text{BIC} = \underbrace{-2 \times \log(\text{verossimilhança})}_{\text{bondade do ajuste}} + \underbrace{(\text{número de parâmetros}) \times \log(\text{tamanho da amostra})}_{\text{penalização}},$$

onde a verossimilhança é avaliada considerando o modelo estimado.

- As penalizações para o AIC e o BIC são 2 e $\log(n)$ respectivamente.
 - BIC tende a selecionar modelos AR de ordens menores quando o tamanho da amostra é moderado ou grande.
- A ordem do processo é identificada através dos modelos que produzem os menores valores para o AIC ou para o BIC.

Processo Autorregressivo de Ordem p - AR(p)

- Em análise de séries temporais, muito do nosso interesse está em fazer previsões a partir dos dados observados.
- Suponha que estejamos no tempo h (**origem**) e tenhamos interesse em prever Y_{h+l} onde $l \geq 1$ (**horizonte**).
 - F_h é a informação disponível em h ;
 - $\hat{y}_h(l)$ é a previsão l -passos a frente de Y_t com origem h .

Processo Autorregressivo de Ordem p - AR(p)

- Previsão 1-passo a frente:

$$\hat{y}_h(1) = E(Y_{h+1}|F_n) = \phi_0 + \phi_1 y_h + \phi_2 y_{h-1} + \dots + \phi_p y_{h+1-p}.$$

- Previsão 2-passos a frente:

$$\begin{aligned}\hat{y}_h(2) &= E(Y_{h+2}|F_n) \\ &= \phi_0 + \phi_1 \hat{y}_h(1) + \phi_2 y_h + \dots + \phi_p y_{h+2-p} \\ &= \phi_0 + \phi_1 (\phi_0 + \phi_1 y_h + \dots + \phi_p y_{h+1-p}) + \phi_2 y_h + \dots + \phi_p y_{h+2-p}.\end{aligned}$$

- Podemos aplicar o mesmo procedimento para computar $\hat{y}_h(k)$ para qualquer k .
- As previsões são combinações lineares dos p valores observados mais recentes da série com coeficientes computados indutivamente a partir dos coeficientes do modelo.
- Previsões convergem rapidamente para a média da série (ϕ_0).

Processos de Médias Móveis (MA)

Processo de Média Móvel de Ordem 1 - MA(1)

- Seja $\{W_t\}$ ruído branco, um processo MA(1) pode ser descrito como a seguir:

$$y_t = c_0 + \theta_1 w_{t-1} + w_t.$$

- Por conveniência, assumimos $c_0 = 0$ para computar as autocovariâncias.

$$\begin{aligned}\gamma_l &= E(Y_t Y_{t-l}) \\ &= E((\theta_1 W_{t-1} + W_t)(\theta_1 W_{t-l-1} + W_{t-l})) \\ &= E(\theta_1^2 W_{t-1} W_{t-l-1}) + E(\theta_1 W_{t-1} W_{t-l}) + E(\theta_1 W_t W_{t-l-1}) + E(W_t W_{t-l}).\end{aligned}$$

- Para $l = 0$, temos:

$$\begin{aligned}\gamma_0 &= E(\theta_1^2 W_{t-1} W_{t-1}) + E(\theta_1 W_{t-1} W_t) + E(\theta_1 W_t W_{t-1}) + E(W_t W_t) \\ &= \theta_1^2 \tau^2 + \tau^2 \\ &= (1 + \theta_1^2) \tau^2.\end{aligned}$$

Processo Média Móvel de Ordem 1 - MA(1)

- Para $l = 1$, temos:

$$\begin{aligned}\gamma_1 &= E(\theta_1^2 W_{t-1} W_{t-2}) + E(\theta_1 W_{t-1} W_{t-1}) + E(\theta_1 W_t W_{t-2}) + E(W_t W_{t-1}) \\ &= \theta_1 \tau^2.\end{aligned}$$

- Para $l > 1$, temos $\gamma_l = 0$.
- Note que a função de autocovariância será zero para toda defasagem maior que 1 em um modelo MA(1).
- $\rho_0 = 1$, $\rho_1 = \theta_1 / (1 + \theta_1^2)$, $\rho_l = 0$ para $l > 1$.

Processo Média Móvel de Ordem 2 - MA(2)

- Seja $\{W_t\}$ ruído branco, um processo MA(2) é dado pela seguinte equação:

$$y_t = c_0 + \theta_1 w_{t-1} + \theta_2 w_{t-2} + w_t.$$

- Assumindo $c_0 = 0$, teremos as autocovariâncias como a seguir:

$$\gamma_0 = (1 + \theta_1^2 + \theta_2^2)\tau^2$$

$$\gamma_1 = (\theta_1 + \theta_1\theta_2)\tau^2$$

$$\gamma_2 = \theta_2\tau^2$$

$$\gamma_l = 0. \text{ para } l > 2.$$

- Consequentemente, temos:

$$\rho_0 = 1$$

$$\rho_1 = (\theta_1 + \theta_1\theta_2)/(1 + \theta_1^2 + \theta_2^2)$$

$$\rho_2 = \theta_2/(1 + \theta_1^2 + \theta_2^2)$$

$$\rho_l = 0. \text{ para } l > 2.$$

Processo Média Móvel de Ordem q - $MA(q)$

- Seja $\{W_t\}$ ruído branco, generalizando os modelos $MA(1)$ e $MA(2)$, descrevemos um modelo $MA(q)$:

$$y_t = c_0 + \theta_1 w_{t-1} + \dots + \theta_q w_{t-q} + w_t.$$

- Processos de médias móveis sempre fracamente estacionários.
 - $E(Y_t) = c_0$;
 - $\text{Var}(Y_t) = (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2)\tau^2$.
- Assumindo $c_0 = 0$, a função de autocovariância γ_l e, conseqüentemente, a função de autocorrelação ρ_l serão iguais a 0 para $l > q$.
- Tal resultado dá uma indicação acerca da escolha da ordem de um processo de médias móveis.

Processo Média Móvel de Ordem q - $MA(q)$

- Assim como verificamos que um processo $AR(1)$ é um processo $MA(\infty)$, também por recursão, podemos verificar que um processo $MA(1)$ é um processo $AR(\infty)$.

$$\begin{aligned}y_t &= \theta_1 w_{t-1} + w_t \\&= \theta_1 (x_{t-1} - \theta_1 w_{t-2}) + w_t \\&= \theta_1 x_{t-1} - \theta_1^2 w_{t-2} + w_t \\&= \theta_1 x_{t-1} - \theta_1^2 (x_{t-2} - \theta_1 w_{t-3}) + w_t \\&= \theta_1 x_{t-1} - \theta_1^2 x_{t-2} - \theta_1^3 w_{t-3} + w_t \\&\vdots \\&= \theta_1 x_{t-1} - \theta_1^2 x_{t-2} - \theta_1^3 w_{t-3} - \dots + w_t\end{aligned}$$

- Ressalta-se que o resultado vale para $|\theta_1| < 1$

Processos Autorregressivos de Médias Móveis (ARMA)

Processos Autorregressivos de Médias Móveis

- Seja $\{W_t\}$ ruído branco, um processo autorregressivo de médias móveis de ordem p e q , $\text{ARMA}(p, q)$, é descrito da seguinte forma:

$$y_t = \mu + \sum_{i=1}^p \phi_i y_{t-i} + \sum_{j=1}^q \theta_j w_{t-j} + w_t.$$

- Uma série temporal é dita um processo ARIMA se, quando tomada a diferença um número finito de vezes, a mesma se torna um processo ARMA.
- $Y \sim \text{ARIMA}(p, d, q)$ se $Y \sim \text{ARMA}(p, q)$ após d diferenças serem tomadas.
 - $Y \sim \text{ARIMA}(p, d, q) \iff \nabla^d Y \sim \text{ARMA}(p, q).$

- Box, G. E. P., and David A. Pierce. 1970. "Distribution of Residual Autocorrelations in Autoregressive-Integrated Moving Average Time Series Models." *Journal of the American Statistical Association* 65 (332): 1509–1526.
- Ljung, G. M., and G. E. P. Box. 1978. "On a measure of lack of fit in time series models." *Biometrika* 65 (2): 297–303.